

utfcode
utf8.sty 3.10 UTF-8 input encoding 13.06.2000
scanner for code UTF-8 installed.

UNIVERSITÉ DE KINSHASA

Faculté des Sciences / Département d'Informatique

RAPPORT DE TRAVAIL PRATIQUE

Implémentation et Analyse de l'Algorithme des Nuées
Dynamiques (Diday, 1971)

Présenté par :

MASIALA NSUNGU Sephora

Master 1 Informatique

Année Académique 2025–2026

Résumé

Ce travail présente l'étude théorique et l'implémentation pratique de l'algorithme des Nuées Dynamiques introduit par Edwin Diday en 1971. Contrairement à la méthode classique des K -moyennes qui modélise chaque classe par un unique centre de gravité, la méthode des nuées dynamiques généralise cette approche en représentant chaque cluster par un noyau formé de plusieurs points étalons.

1 Introduction

En apprentissage automatique non supervisé, le partitionnement de données (clustering) vise à regrouper des objets similaires au sein d'une même classe tout en maintenant une forte séparation entre des classes différentes.

L'algorithme classique des K -means souffre parfois d'une sensibilité marquée aux conditions initiales et d'une incapacité à saisir des structures géométriques complexes. L'approche des **Nuées Dynamiques** (Diday, 1971) répond à ce problème en introduisant la notion de *noyaux* (ou étalons) composés de k éléments représentatifs par classe.

2 Fondements Théoriques

Soit un ensemble de N points de données $X = \{x_1, x_2, \dots, x_N\} \subset \mathbb{R}^d$ à partitionner en P classes $C = \{C_1, C_2, \dots, C_P\}$.

Chaque classe C_g est représentée par un noyau $K_g = \{p_{g,1}, p_{g,2}, \dots, p_{g,k}\}$ composé de k points étalons ($k \geq 1$).

2.1 Mesure de Distance au Noyau

La distance d'un point x_i à un noyau K_g est définie comme la moyenne des distances euclidiennes entre le point x_i et l'ensemble des éléments constituant le noyau :

$$D(x_i, K_g) = \frac{1}{|K_g|} \sum_{p \in K_g} \|x_i - p\|_2$$

2.2 Étapes d'Optimisation

L'algorithme procède par itérations successives alternant deux phases principales :

1. **Étape d'Affectation (Phase A)** : Pour chaque donnée x_i , on détermine la classe dont le noyau minimise la distance :

$$C_g = \{x_i \in X \mid D(x_i, K_g) \leq D(x_i, K_h), \forall h \neq g\}$$

2. **Étape de Représentation (Phase R)** : Pour chaque classe C_g obtenue, on sélectionne un nouveau noyau K'_g formé par les k points de C_g qui minimisent l'inertie de la classe.

3 Architecture de l'Implémentation (algo.py)

L'implémentation a été réalisée en langage Python à l'aide des bibliothèques scientifiques NumPy et Matplotlib.

3.1 Structure de la Classe DynamicClouds

Le module principal est structuré autour de la classe `DynamicClouds` :

- `__init__` : Définit les hyperparamètres (nombre de clusters, taille des noyaux k , nombre maximal d'itérations, tolérance de convergence).
- `_distance` : Calcule la distance moyenne euclidienne entre une observation et un noyau.
- `fit` : Exécute la boucle d'optimisation jusqu'à la stabilisation des noyaux ou le dépassement du nombre maximal d'itérations.

3.2 Extrait du Code Source

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 class DynamicClouds:
5     def __init__(self, n_clusters=3, kernel_size=1, max_iter=100, tol=1e
6         -4):
7         self.n_clusters = n_clusters
8         self.kernel_size = kernel_size
9         self.max_iter = max_iter
10        self.tol = tol
11        self.kernels = None
12        self.labels = None
13
14    def _distance(self, x, kernel):
15        distances = [np.linalg.norm(x - k_point) for k_point in kernel]
16        return np.mean(distances)
```

Listing 1 – Structure principale de l'algorithme dans algo.py

4 Expérimentation et Résultats

L'algorithme a été évalué sur des jeux de données synthétiques à deux dimensions. L'utilisation de noyaux à plusieurs éléments ($k > 1$) montre une meilleure stabilité face au bruit comparée à l'algorithme des K -means classique.

5 Discussion et Analyse Comparative

La flexibilité apportée par les Nuées Dynamiques présente plusieurs avantages et contreparties :

5.1 Avantages de la Méthode

- **Robustesse géométrique** : Capacité à capturer des formes de clusters non sphériques.
- **Moindre sensibilité aux valeurs aberrantes** : La moyenne sur plusieurs étalons amortit l'impact d'un point isolé.

5.2 Limites et Complexité

- **Complexité algorithmique** : Le calcul répétitif des distances par rapport à chaque élément du noyau augmente le temps d'exécution.
- **Choix du paramètre k** : La taille du noyau k constitue un hyperparamètre supplémentaire à régler.

6 Conclusion

Ce travail pratique a permis de concrétiser les concepts théoriques développés par E. Diday (1971). L'implémentation en Python via le fichier `algo.py` démontre l'efficacité opérationnelle des noyaux dynamiques pour le partitionnement de données. Le projet complet ainsi que le code source sont versionnés et disponibles sur le dépôt GitHub officiel du projet.

Références

1. Diday, E. (1971). *La méthode des nuées dynamiques*. Revue de statistique appliquée, 19(2), 19-34.
2. MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Proceedings of the fifth Berkeley symposium on mathematical statistics and probability.